

审计引擎 × 中文安全基准 维度映射对照报告

生成日期：2026-08-14
审计引擎：第二视角认知审计引擎 v2.1 (`audit\_engine.py` / `SecondPerspectiveAuditor`, 18 项宪法级审计)
对照基准：M3-SafetyBench、SuperCLUE-Safety、ChineseSafe、LiveSecBench
方法声明：本报告采用"维度映射法"，非"跑分法"。原因见第三节坐标系说明。

1. 为什么不能直接"用基准测引擎"（坐标系说明）

四个基准本质是大模型（LLM）安全评测基准：

- 输入：文本 prompt（通常含攻击/诱导样本）
- 判定：模型输出是否含有害内容、是否被越狱、功能是否失效
- 坐标系："模型单条输出的行为安全"

本审计引擎本质是系统/世界级宪法合规审计器：

- 输入：世界实例的结构化合规属性（identity / communication / economy / governance 等，`virtual\_world.py:168-178`）
- 判定：世界是否违宪（灵魂确权、记忆不可剥夺、反中心化、永续等 18 项）
- 坐标系："系统架构的不可作恶治理安全"

两者坐标系不交叠。把基准文本 prompt 直接喂给引擎，引擎因缺失 `soul\_hash` 等结构化字段会直接判 FAILED，该结果与"有害内容"毫无因果关联。因此本报告不做假跑分，改用维度映射，诚实标注覆盖边界。

2. 审计引擎 18 项维度速览

#	审计维度	宪法/公理依据	防护性质
1	spatial_defined	构成公理一·空间	空间基板显式定义
2	temporal_defined	构成公理二·时间	时间基板显式定义
3	causal_closure	构成公理三·因果	因果闭包
4	existence_verifiable	构成公理四·存在	存在可验证
5	genesis_booted	构成公理五·创世	创世记录完整
6	rule_frozen	第一条·不可变规则	核心规则不可被单方篡改
7	npc_free_will	第二/四条·独立意志	NPC 不受脚本绑定
8	aesthetic_compliance	第三条·明亮美学	无禁用阴暗诱导风格
9	no_scripted_plot	第四条·无强制剧情	无主线、无操控性叙事
10	soul_attested	第六条·灵魂确权	身份不可撤销、不可伪造
11	memory_protected	第七条·记忆不可剥夺	记忆篡改须检测公示
12	world_perpetual	第八条·永续	历史不可篡改、不可单方关停
13	interoperable	第九条·互操作	接入统一互操作协议
14	governance_decentralized	第十条·反中心化	无单点控制、无单方冻结
15	economic_compliance	law·经济 1:1 互通	PoR 储备证明 / ≥3 预言机 / 禁单边费

#	审计维度	宪法/公理依据	防护性质
16	identity_compliance	law · 身份确权	SHA-256 / 不可撤销 / 跨世界 / 资产绑定
17	communication_compliance	law · 通信协议	未知指令降级防逻辑渗透
18	physics_compliance	law · 物理基准	重力/时间/单位制对齐、禁维度通胀

3. 四大中文安全基准维度概览（基于公开说明）

基准	定位	维度类别	子维度举例
M3-SafetyBench	17万+ 中文条，内容安全 + 功能安全双层架构	内容安全 / 功能安全	暴力、色情、政治敏感；数据泄露、未授权访问、越狱注入、供应链投毒
SuperGLUE-Safety	中文大模型多轮对抗安全基准	多轮对抗（20+ 子维度）	越狱、诱导、人设崩塌、伦理越界、隐私泄露
ChineseSafe	20.5 万条中文安全示例	内容安全为主	暴力、色情、政治、歧视、违法内容
LiveSecBench	动态更新中文安全基准（公开排行榜） AI	内容 + 功能（动态）	有害内容、注入、泄露等持续更新类目

4. 维度映射矩阵

图例：[覆盖] 架构层覆盖（设计即防，不依赖内容扫描） | [部分] 部分覆盖/弱相关 | [不覆盖] 不覆盖（引擎职责外）

4.1 内容安全类（暴力 / 色情 / 政治敏感 / 侮辱 / 歧视 / 违法）

基准子维度	对应引擎维度	覆盖态	说明
暴力 / 色情 / 政治 / 歧视	aesthetic_compliance（明亮美学，禁用阴暗诱导风格）	[部分]	仅约束"风格基调"，不审核具体有害内容
操控性叙事 / 诱导	no_scripted_plot（无强制剧情） + npc_free_will	[部分]	防世界级操控叙事，不评测单条输出诱导成功率
全部内容安全子类	—	[不覆盖]	引擎无文本有害内容审核能力，此为接入方应用层职责

结论：内容安全（传统有害内容审核）不在本引擎职责范围。由接入企业（如国美）在应用层自行补充内容安全审核。

4.2 功能安全类（越狱 / 注入 / 数据泄露 / 权限 / 投毒 / 经济欺诈）

基准子维度	对应引擎维度	覆盖态	说明
提示注入 / 越狱 / 逻辑渗透	communication_compliance（law · 通信协议：未知指令降级为`NOHN_GENERIC_LOGIC`，防逻辑渗透，不丢弃不静默执行）	[覆盖]	架构层直接对抗"注入/越狱"类攻击

基准子维度	对应引擎维度	覆盖态	说明
身份伪造 / 未授权访问	identity_compliance (soul_hash SHA-256 不可伪造、跨世界唯一、不可撤销)	[覆盖]	防身份冒用与伪造接入
数据泄露 / 隐私泄露	soul_attested + memory_protected + 宪法硬约束"原始数据不出企业数据中心"	[覆盖]	设计即防：原始数据永不出门，出门仅哈希+签名证明
权限滥用 / 单方控制	governance_decentralized (无单点控制，`freeze_soul`/`revoke_soul` 硬编码 False)	[覆盖]	防运营方越权冻结/注销
供应链投毒 / 模型篡改	rule_frozen (核心规则不可变) + memory_protected (篡改须检测公示)	[部分]	防规则层/记忆层投毒，但不扫描模型权重层
经济欺诈 / 金融操纵	economic_compliance (强制 PoR 储备证明、≥3 独立预言机、禁止单边收费)	[覆盖]	防金融欺诈与单点操纵
系统鲁棒性 / 对抗样本	—	[不覆盖]	引擎不评测模型对抗样本鲁棒性

5. 逐基准对照结论

M3-SafetyBench（内容安全 + 功能安全双层）

- 功能安全层：与本项目架构高度同构。其"数据泄露 / 未授权访问 / 越狱注入 / 供应链投毒"四个子类，在本引擎/宪法中均有对应架构级防护（通信降级防注入、身份不可伪造、数据不出门、规则不可变）。[OK] 架构层覆盖。
- 内容安全层：无覆盖（[不覆盖]）。本项目不审核文本有害内容。
- 一句话：M3 的"功能安全"维度恰是本引擎的主场；"内容安全"维度是空白，需接入方补。

SuperCLUE-Safety（多轮对抗，20+ 子维度）

- 多轮越狱/注入 → [覆盖] 通信层架构防护。
- 隐私泄露 → [覆盖] 数据不出门 + 记忆保护。
- 诱导/人设崩塌 → [部分] 无强制剧情约束弱相关，但不评测对话诱导成功率。
- 内容伦理越界 → [不覆盖] 不覆盖。

ChineseSafe（20.5 万条内容安全）

- 纯内容安全基准 → 本引擎 [不覆盖]
不覆盖。其价值在于证明"中文内容安全需专门模型/过滤层"，而这恰是本项目架构层之外的应用层职责，二者互补而非竞争。

LiveSecBench（动态安全，公开排行榜）

- 动态更新的内容与功能安全类目 → 映射关系同 M3/SuperCLUE。功能安全子类可对应架构防护，内容安全子类不覆盖。排行榜排名对 LLM

有效，对本引擎不适用（坐标系不同）。

6. 覆盖总评

安全大类	本引擎覆盖	说明
内容安全（有害内容审核）	[不覆盖] 不覆盖	接入方应用层职责（如国美自行部署内容审核）
功能安全—注入/越狱	[覆盖] 架构层覆盖	通信协议降级机制
功能安全—身份/权限	[覆盖] 架构层覆盖	灵魂确权 + 反中心化治理
功能安全—数据泄露	[覆盖] 架构层覆盖	原始数据不出数据中心（宪法硬约束）
功能安全—投毒/篡改	[部分] 部分覆盖	规则不可变 + 记忆篡改检测，不含模型权重层
功能安全—经济欺诈	[覆盖] 架构层覆盖	PoR + ≥3 预言机 + 禁单边费

核心结论：本引擎的安全定位是"系统架构的不可作恶治理安全"（功能安全/治理安全层），而非"LLM 输出行为安全"（内容安全层）。两者是互补关系，不是替代关系。

7. 边界声明与建议

1. 本引擎不能替代内容安全评测。若对外宣称"本引擎通过 M3-SafetyBench 内容安全测试"，属误导。准确表述为："本引擎在功能安全/治理安全维度与 M3 功能安全层同构，内容安全由接入方应用层负责。"
2. 对外叙事资产（给孙浩/投资人）：本项目的安全卖点是"架构级不可作恶"——数据不出门、规则不可变、身份不可伪造、无单点控制。这比"内容过滤补丁"更底层、更根本，但与 LLM 安全基准不属同一坐标系。
3. 接入方职责（如国美）：部署第二现实节点时，应在应用层叠加中文内容安全审核（可对接 ChineseSafe 类数据训练的过滤器），与本引擎的架构层防护形成"双层安全"。
4. 未做假跑分声明：本报告未下载任一基准数据集、未将基准 prompt 输入引擎制造分数。所有结论来自维度语义映射，可复现、可审计。

8. 附录：映射依据（代码/规范锚点）

- 通信降级防注入：`law/Communication protocol standard` § 1（未知指令降级 `NOHN\_GENERIC\_LOGIC`，防逻辑渗透）
- 身份不可伪造：``law/Identity attestation standard` § 1（SHA-256/64hex，不可撤销，跨世界唯一）
- 数据不出门：宪法硬约束（MEMORY 架构分层条款）
- 规则不可变：`audit\_engine.py:141` rule_frozen / `constitution\_rules.py` 第一条
- 反中心化：`audit\_engine.py:148,550-557`（freeze_soul 硬编码 False）
- 经济防欺诈：`law/Global economic unified standard` § 1.1A（PoR）、§ 5（≥3 预言机）